

Tarefa

1. Use uma [Gated recurrent units \(GRUs\)](#) e uma RNN clássica para replicar os experimentos realizados com a LSTM:
 - [GRU em Pytorch](#)
 - [RNN clássica em Pytorch](#)
2. Gere receitas com os modelos variando o valor do hiperparâmetro temperatura.
3. Usando *perplexity*, compare os resultados obtidos pelos modelos: GRU vs. RNN clássica vs. LSTM.

Entregáveis:

1. Notebook .ipynb
2. Relatório .pdf

RNN Clássica

Implementação

```
self.embedding = nn.Embedding(
    vocab_size,
    embedding_dim,
    padding_idx=0
)
self.rnn = nn.RNN(
    input_size=embedding_dim,
    hidden_size=hidden_size,
    batch_first=True
)
self.fc = nn.Linear(
    hidden_size,
    vocab_size
)
```

Prompts utilizados

Para o primeiro prompt, as gerações com baixas temperaturas apresentaram uma boa estrutura sintática, mas semanticamente não fizeram sentido. A geração com temperatura alta acabou por ser a que mais fez sentido no contexto da query, apesar de ter um número '5' solto no meio da frase.

- "recipe for roasted vegetables"
 - Temp = 0: in a large bowl , combine the sugar and salt
 - Temp = 0.2: in a bowl whisk together the flour , the baking
 - Temp = 1: preheat the oven to 350°f . 5 . bake for

Já para este prompt, o resultado foi inverso. As respostas de temperatura mais baixa foram as que mais fizeram sentido para o contexto. O texto gerado com temperatura 1 não fez o menor sentido para a receita proposta.

- "recipe for mac and cheese"
 - Temp = 0: preheat oven to 350°f . butter a 9 -
 - Temp = 0.2: preheat oven to 350°f . butter and flour 9
 - Temp = 1: stir anise (but sauce can be kept overed

GRU

Implementação

```
self.embedding = nn.Embedding(
    vocab_size,
    embedding_dim,
    padding_idx=0
)
self.gru = nn.GRU(
    input_size=embedding_dim,
    hidden_size=hidden_size,
    batch_first=True
)
self.fc = nn.Linear(
    hidden_size,
    vocab_size
)
```

Prompts utilizados

A GRU se mostrou bem melhor no primeiro prompt, com todas as respostas, mesmo que diferentes, fazendo algum sentido para a receita sugerida.

- "recipe for roasted vegetables"
 - Temp = 0: preheat oven to 450°f . toss potatoes with 1 /
 - Temp = 0.2: preheat oven to 450°f . toss potatoes with 1 /
 - Temp = 1: fill a large saucepan with 1 water and drain well

Já para esta receita, as respostas da GRU não fizeram o menor sentido em nenhum dos testes.

- "recipe for mac and cheese"
 - Temp = 0: combine all ingredients in a cocktail shaker and shake
 - Temp = 0.2: combine all ingredients in a cocktail shaker and shake
 - Temp = 1: line the bottom rack with two 1 - inch

LSTM

Implementação

```
self.embedding = nn.Embedding(
    vocab_size,
    embedding_dim,
    padding_idx=0
)
self.lstm = nn.LSTM(
    input_size=embedding_dim,
    hidden_size=hidden_size,
    batch_first=True
)
self.fc = nn.Linear(
    hidden_size,
    vocab_size
)
```

Prompts utilizados

- "recipe for roasted vegetables"
 - Temp = 0: preheat oven to 350°f . butter a large baking sheet

- Temp = 0.2: preheat oven to 350°F . rinse turkey inside and out
- Temp = 1: preheat oven to 475°F . brush each 4 slightly inside
- "recipe for mac and cheese"
 - Temp = 0: 1 . preheat the oven to 350°F . in
 - Temp = 0.2: 1 . preheat the oven to 350°F . in
 - Temp = 1: 1 . preheat the oven to 425°F . slowly

Perplexity

Modelo	Perplexity	Melhoria vs RNN
RNN Clássica	13.10	- (baseline)
GRU	10.31	21.3% melhor
LSTM	10.31	21.3% melhor

Embora GRU e LSTM tenham perplexity idêntica, a qualidade percebida varia:

- **LSTM:** Gerações mais estruturadas (numeração, passos lógicos)
- **GRU:** Gerações funcionais, mas ocasionalmente comete erros semânticos, como "cocktail shaker"